
Modul 10: Big Data Processing & Distributed Analytics

Bank Materi Sains Data (BMSD) — Apache Spark RDD, Catalyst Optimizer, Stream Processing

Sumber: Bank Materi Sains Data (BMSD) • Terintegrasi Learning OS Dual Reader

Bab 1: Paradigma Komputasi Terdistribusi & Spark RDD

Apache Spark menyediakan komputasi in-memory terdistribusi berbasis Resilient Distributed Datasets (RDD).

Toleransi kesalahan dicapai melalui pencatatan Lineage Graph, memungkinkan partisi data yang hilang dihitung ulang tanpa replikasi disk penuh.

Bab 2: Spark SQL & Catalyst Optimizer

Catalyst Optimizer secara otomatis mengoptimalkan query logis menjadi rencana eksekusi fisik (predicate pushdown, column pruning).

Pipeline Lambda dan Kappa mengintegrasikan batch analytics dengan streaming event berlatensi sub-detik.