
SD3102 — Komputasi Paralel & Big Data

Bank Materi Sains Data (BMSD) • Semester 5 (Prodi) • Mata Kuliah Wajib (3 SKS)

Deskripsi Mata Kuliah:

Paradigma MapReduce, ekosistem Apache Hadoop/Spark, Resilient Distributed Datasets (RDD), in-me...

Bab 1: Arsitektur Big Data & Apache Spark RDD

Apache Spark menyediakan komputasi in-memory terdistribusi. RDD bersifat immutable dan fault-tolerant melalui pencatatan Lineage Graph, memungkinkan partisi yang hilang dihitung ulang tanpa replikasi disk berkali-kali.

Rumus Kunci (Resilient Distributed Dataset (RDD)):

$RDD = Transformation(LineageGraph)$

Bab 2: Spark Catalyst Optimizer & Streaming

Spark SQL mengoptimalkan query logis ke rencana fisik melalui predicate pushdown dan projection pruning. Structured Streaming memproses data kontinu berlatensi sub-detik.