
Modul 03: Exploratory Data Analysis & Feature Engineering

Bank Materi Sains Data (BMSD) — Pembersihan Data, Outlier, & Normalisasi

Sumber: Bank Materi Sains Data (BMSD) • Terintegrasi Learning OS Dual Reader

Bab 1: Penanganan Missing Values & Kategori

Tipe missing data: MCAR (Missing Completely at Random), MAR (Missing at Random), dan MNAR (Missing Not at Random).

Metode imputasi: Mean/Median untuk data numerik simetris, KNN Imputer, dan MICE (Multivariate Imputation by Chained Equations).

Encoding variabel kategorikal: One-Hot Encoding untuk nominal berfrekuensi rendah, dan Target/Frequency Encoding untuk kardinalitas tinggi.

Bab 2: Deteksi Outlier & Penskalaan Fitur

Deteksi outlier statistik menggunakan metode Interquartile Range (IQR): Batas Atas = $Q3 + 1.5 \cdot IQR$, Batas Bawah = $Q1 - 1.5 \cdot IQR$.

Penskalaan fitur: StandardScaler $z = (x - \mu) / \sigma$ menghasilkan mean 0 dan variansi 1, sangat krusial bagi model berbasis jarak (KNN, SVM, K-Means).